



Fundação Universidade Federal do ABC

Pró reitoria de pesquisa

Av. dos Estados, 5001, Santa Terezinha, Santo André/SP, CEP 09210-580

Bloco L, 3º Andar, Fone (11) 3356-7617

iniciacao@ufabc.edu.br

Relatório Final de Iniciação Científica
referente ao Edital: 01/2025

Nome do aluno: Thiago Fernandes Dias

Assinatura do aluno:

Nome do orientador: Paulo Henrique Pisani

Assinatura do orientador:

Nome do coorientador: Francisco de Assis Zampiroli

Assinatura do coorientador:

Título do projeto: Avaliação de técnicas de extração de características para reconhecimento de usuários pela impressão digital

Palavras-chave do projeto: biometria; aprendizado de máquina; classificação

Área do conhecimento do projeto: Ciências Exatas e da Terra; Ciência da Computação; Metodologia e Técnicas da Computação

Bolsista: Sim, CNPq

Santo André

2026

Resumo

Para fazer

Sumário

1	Introdução	4
2	Fundamentação teórica	5
2.1	Biometria por Impressão Digital	5
2.2	Formas de representação de impressões digitais	6
2.3	Extração de características de digitais	6
3	Objetivos	9
4	Metodologia	10
4.1	Conjuntos de dados	10
4.1.1	<i>Fingerprint Verification Competition (FVC)</i>	10
4.1.2	Neurotechnology	11
4.2	Métricas	11
4.3	Algoritmos	12
4.3.1	Arquitetura do <i>DeepPrint</i>	12
4.3.2	Arquitetura do FLARE	13
4.3.3	Representação baseada em Cilindros	16
4.4	Experimentos	16
4.4.1	Treinamento do <i>DeepPrint</i>	17
4.4.2	Treinamento do FLARE	17
4.4.3	Testes com os modelos pré-treinados	18
5	Resultados e discussão dos resultados	19
6	Conclusões e perspectivas de trabalhos futuros	21
	REFERÊNCIAS	24

1 Introdução

A Biometria é uma forma de identificação que se baseia nas características físicas e comportamentais das pessoas, como íris, impressões digitais e voz. Sistemas biométricos operam sobre a premissa de que tais características são únicas para cada indivíduo, e, se puderem ser extraídas através de sensores, podem ser convertidas para representações numéricas e processadas por algoritmos de reconhecimento de padrões (JAIN; FLYNN; ROSS, 2007). Como os dados biométricos são particulares a cada pessoa eles podem ser usados como forma de autenticação e de forma mais segura do que o uso de senhas (JAIN; ROSS; PANKANTI, 2006).

Neste projeto, será dado o enfoque na vertente física, em particular, na biometria através de impressões digitais. Essa modalidade biométrica se baseia nos padrões de pequenas elevações e depressões na pele das pontas dos dedos (MALTONI et al., 2022). Os usuários são então reconhecidos com base nas diferenças nesses padrões.

Conforme definido por Jain, Ross e Prabhakar (2004), sistemas biométricos são sistemas de reconhecimento de padrões que extraem características de dados biométricos e então comparam as características extraídas com uma referência biométrica em um banco de dados. Nesse sentido, Maltoni et al. (2022) explica que, para a autenticação através de impressões digitais, a representação das características extraídas das imagens é um problema fundamental da verificação de digitais.

Como não há a garantia de que as imagens da impressão digital de um mesmo dedo serão exatamente iguais em termos de intensidade de pixel, ruídos de fundo, orientação e formato, há a necessidade de se extrair características a partir das quais seja possível diferenciar digitais com uma boa acurácia e que sejam invariantes para uma dada digital. Somente assim o uso de digitais em sistemas de autenticação se tornariam viáveis.

O objetivo deste trabalho é avaliar diferentes técnicas de extração de características para reconhecimento de usuários pela impressão digital. As demais seções do projeto estão organizadas da seguinte forma: na Seção 2, são introduzidos conceitos sobre reconhecimento de usuários pela impressão digital e a revisão bibliográfica realizada; na Seção 3, são definidos os objetivos; na Seção 4, a metodologia é descrita, incluindo conjuntos de dados e métricas; na Seção 5 são exibidos os resultados obtidos e na Seção 6 é feita a conclusão do relatório.

2 Fundamentação teórica

Esta seção apresenta algumas constatações sobre a pesquisa na área de impressões digitais e técnicas de extração de características.

2.1 Biometria por Impressão Digital

O termo “Impressão Digital” no contexto de biometria por impressões digitais se refere ao padrão de pequenos cumes e vales que podem ser observados na ponta dos dedos das pessoas. Ao longo da evolução da raça humana o desenvolvimento de digitais está relacionado à capacidade de segurar objetos com as mãos. O padrão específico de cumes e vales, assim como outras características do corpo, é definido por fatores genéticos e ambientais (MALTONI et al., 2022).

O reconhecimento de que as impressões digitais são únicas para cada dedo de cada pessoa ocorreu em 1880 com base em observações experimentais de Henry Fauld (MOENSSENS, 1971). Em 1993, a unicidade de impressões digitais foi reconhecida por entidades governamentais do Reino Unido, e foi determinado que as digitais de criminosos seriam coletadas no momento da prisão. Assim, seria possível identificar pessoas a partir de impressões digitais coletadas em cenas de crime a partir da análise feita por especialistas em investigação forense. Conforme explica Maltoni et al. (2022), apesar dos esforços para tornar mais eficiente o processo manual de identificação por impressões digitais, o aumento da demanda tornou esse método inviável. O sistema de classificação manual era ineficiente, o treinamento de novos profissionais capazes de empregá-lo era demorado e a comparação visual de impressões digitais era cansativa e lenta. Por isso, os órgãos de segurança pública começaram a investir em soluções eletrônicas e automatizadas, o que levou ao desenvolvimento dos Sistemas Automatizados de Identificação de Impressões Digitais (*Automated Fingerprint Identification Systems* - AFIS)

Inicialmente usados por forças de segurança, esses sistemas hoje também são aplicados em diversas áreas não forenses devido ao aumento das preocupações com segurança e fraudes de identidade. Por exemplo, sistemas biométricos tem sido adotados em *Internet Banking* e autenticação de usuários em dispositivos móveis. Nesse contexto, as digitais são coletadas com sensores especializados que geram imagens das impressões digitais, que são processadas a fim de se obter uma forma de representação que pode ser usada para verificação (MALTONI et al., 2022).

2.2 Formas de representação de impressões digitais

Maltoni et al. (2022) enfatiza que uma boa representação de uma impressão digital deve: (i) conter informações que possibilitem distinguir entre duas amostras; (ii) ser extraída de forma rápida e fácil; e (iii) ser compacta, de modo a poder ser armazenada em sistemas biométricos com pouca capacidade. Representações baseadas em imagens, em geral, não são adequadas devido às variações de iluminação, resolução, qualidade e aos ruídos provocados por cicatrizes ou outras lesões nos dedos, especialmente em pessoas que realizam trabalhos manuais com frequência.

O autor supracitado divide os atributos que podem ser extraídos de uma impressão digital em três níveis diferentes:

- **Nível 1:** também chamado de nível global, há atributos como o padrão das curvaturas das linhas nas imagens, delimitadas pelos cumes e vales da impressão digital. A partir dela podem ser determinados os “pontos singulares”, que são os centros das curvaturas dessas linhas (LEVI; SIROVICH, 1972). As imagens de orientação e frequência e o formato da digital (que serão definidos posteriormente) também são considerados atributos de escopo global;
- **Nível 2:** são as características de escopo local, que exigem uma análise em uma escala menor da impressão digital. Dentre elas as que são mais facilmente observadas em sensores convencionais são as *bifurcações de cume*, onde um cume se divide em dois, e *terminações de cume*, onde um cume termina em um vale. Tais características são chamadas de *minúcias*, e são normalmente definidas pela sua posição na impressão digital e orientação (ângulo);
- **Nível 3:** são atributos relacionados aos próprios cumes, como formato, largura, contorno e a posição e o formato dos poros excretores de suor. Essas características são altamente distintivas, porém só podem ser extraídas de impressões digitais com alta resolução (acima de 1000 dpi).

2.3 Extração de características de digitais

Com o objetivo de selecionar os métodos que seriam avaliados neste projeto foi feita uma revisão bibliográfica sobre artigos que descreviam métodos de extração que, preferencialmente, utilizassem algoritmos de Aprendizado de Máquina e que utilizassem conjuntos de dados públicos para treinamento e teste dos modelos, para facilitar reprodutibilidade.

Na Tabela 1 há alguns dos artigos lidos e as técnicas de extração de características propostas.

Tabela 1 – Revisão Bibliográfica

Referência	Conjunto de dados	Métricas	Código aberto
Cappelli, Ferrara e Maltoni (2010)	FVC2006	EER, FMR	Sim
Nguyen, Cao e Jain (2018)	FVC2002, FVC2004, NIST SD27	F1 Score, Precisão, <i>Recall</i>	Sim
Engelsma, Cao e Jain (2021)	Privado, NIST SD4, NIST SD14, FVC2004	<i>Acc</i> , FMR	Sim
Ezeobijesi e Bhanu (2017)	NIST SD27, WVU, IIITD	MDR, FDR, SA	Não
Tang, Gao e Feng (2017)	Privado, NIST SD27	<i>Recall</i> , Precisão, F1 Score	Não
Tang et al. (2017)	Privado, NIST SD27	Precisão, <i>Recall</i>	Sim
Zhang, Xin e Feng (2019)	Privado, FVC2002, FVC2004	EER, FMR, FNMR	Não
Li et al. (2019)	Privado, NIST SD4, NIST SD14	Top-K ER	Não
Pan et al. (2026)	Privado, NIST SD4, NIST SD14, SD27, SD302/N2N, FVC2002, FVC2004, FVC2006	Curvas DET, TAR com FAR fixa	Sim

Em (CAPPELLI; FERRARA; MALTONI, 2010) foi proposta uma forma de representação chamada de *Minutia Cylinder-Code*. Ela é baseada em estruturas de dados 3D, os cilindros, que codificam os ângulos das minúcias e as distâncias entre elas.

Nguyen, Cao e Jain (2018) criaram a *MinutiaeNet*, que é um modelo composto por duas redes neurais convolucionais, a *CoarseNet*, para estimar os mapas de *scores* de minúcias com base em informações de domínio, e a *FineNet*, para refinamento dos *scores*.

Engelsma, Cao e Jain (2021) introduziram a *DeepPrint*, uma CNN que extrai uma representação de tamanho fixo utilizando alinhamento por Transformadores Espaciais (JADERBERG et al., 2016), informações de domínio e Aprendizado Multitarefa (CARUANA; PRATT; THRUN, 1997).

Ezeobijesi e Bhanu (2017) criaram uma técnica para segmentação de impressões digitais utilizando uma rede neural profunda composta por pilhas de Máquinas de Boltzmann Restritas

(*Restricted Boltzmann Machine*, RBM) para delimitar impressões digitais latentes classificando seções da imagem entre duas classes: “impressão digital” e “*background*”.

Tang, Gao e Feng (2017) utilizaram uma Rede Neural Totalmente Convolutiva (*Fully Convolutional Network*, FCN) para selecionar seções da imagem com uma probabilidade alta de conter uma minúcia. As seções selecionadas serviram de entrada para uma CNN dedicada a classificação propriamente dita, que também calculava a orientação das minúcias.

Tang et al. (2017) criaram a *FingerNet* é uma CNN que extrai um mapa de minúcias utilizando informações de domínio como orientação dos cumes e segmentação, que também são extraídos pela rede, além de realçar as digitais.

Zhang, Xin e Feng (2019) utilizaram duas CNNs baseadas na arquitetura ResNet (SZEGEDY et al., 2017), uma que extrai uma representação de tamanho fixo e outra um mapa de minúcias. A verificação é feita através de cálculo de distâncias de ambas as representações.

Li et al. (2019) desenvolveram de uma FCN que extrai uma representação de tamanho fixo com base em atributos globais e locais. O treinamento é feito utilizando porções da imagem (chamados de “*patches*”) centrados nas minúcias. Na fase de indexação, a rede recebe a imagem completa da digital, e utiliza *Global Average Pooling* (GAP) para agregar todas as informações locais extraídas pela FCN em uma única representação global.

Em (PAN et al., 2026) é apresentado o FLARE, um framework de reconhecimento de impressões digitais baseado na extração de representações de tamanho fixo na forma de um tensor. O método opera em três etapas integradas: inicialmente, alinha a imagem em um sistema de coordenadas padronizado utilizando métodos complementares de estimativa de pose 2D; a seguir, submete a imagem a duas estratégias de aprimoramento (UNetEnh e PriorEnh) que melhoram a clareza das cristas e suprimem o ruído de fundo preservando a textura original da modalidade da captura; por fim, uma rede neural extrai um descritor denso tridimensional que foca exclusivamente na área útil da impressão digital, codificando com alta precisão as informações espaciais globais e locais (minúcias).

Dentre técnicas que utilizam redes neurais profundas para extração de características as que se destacaram são o mapa de minúcias, que é uma representação de tamanho variável que armazena a posição de cada minúcia e sua orientação, e as representações de tamanho fixo, que podem ser os pesos das camadas totalmente conectadas das CNN imediatamente antes do cálculo das probabilidades de cada uma das classes (normalmente de qual dedo a digital foi coletada), isso é, um vetor unidimensional, ou um descritor denso multidimensional, capaz de

agregar mais características das digitais, como segmentação e posição das minúcias. Conforme explica Engelsma, Cao e Jain (2021), a vantagem das representações de tamanho fixo são a necessidade de menos poder computacional para verificação, que pode ser feita por um simples cálculo de distância e comparação com um limiar de corte, e de espaço para armazenamento.

Outro aspecto que esteve presente nos experimentos foi a utilização de informações de domínio, que são as características intrínsecas das digitais (MALTONI et al., 2022). Quando essas informações são incluídas no treinamento dos modelos ou aprendidas em conjunto com as representações o seu desempenho tende a ser superior do que utilizar atributos mais abstratos, como apenas a textura das digitais.

Nos experimentos desenvolvidos nos artigos foram utilizados conjuntos de dados públicos e privados, com diferentes características. Por exemplo, Zhang, Xin e Feng (2019) utilizou impressões digitais parciais de alta resolução, o que torna viável a inclusão de informações sobre os atributos de Nível 3 na rede neural. Já em (TANG; GAO; FENG, 2017) foram utilizadas impressões digitais latentes, que são coletadas em cenas de crimes quando pessoas tocam em objetos (MALTONI et al., 2022) e normalmente apresentam uma alta quantidade de ruídos. No caso do FLARE foram necessários diversos bancos de imagens diferentes e técnicas de *Data Augmentation* para treinar cada uma das redes neurais que compõem o *framework*, como o Diverse Pose Fingerprint (DPF), com ampla variação de pose, e imagens de alta resolução com degradações simuladas (variações de umidade, cicatrizes e desfoque).

Destas técnicas foram encontradas implementações da MCC, *MinutiaeNet*, *FingerNet*, *DeepPrint*, FLARE e o MCC. Além das implementações das técnicas foram encontrados modelos pré-treinados do *DeepPrint*, disponibilizado por Rohwedder et al. (2023) no site ¹, e também dos módulos que compõem o FLARE, como os pesos das redes de realce UNetEnh e PriorEnh disponíveis no site ², as redes de alinhamento VotingPose e RegressionPose e a rede de extração da representação densa, FDD, disponíveis no site ³, que são repositórios públicos do próprio autor do artigo.

3 Objetivos

Este projeto tem o objetivo de **avaliar diferentes técnicas de extração de características para o reconhecimento de usuários pela impressão digital**. Para isso, será estudado o

¹ <<https://github.com/tim-rohwedder/fixed-length-fingerprint-extractors>>

² <https://github.com/Yu-Yy/FLARE_ENH>

³ <<https://github.com/Yu-Yy/FLARE>>

processo de extração de características a partir de imagens de impressão digital e sua representação.

Os objetivos específicos do projeto são:

- Selecionar conjuntos de dados de impressão digital (ver Seção 4);
- Selecionar técnicas de extração de características para reconhecimento de usuários pela impressão digital;
- Realizar experimentos comparando as diferentes técnicas de extração de características;
- Avaliar as técnicas de extração de características sob diversos aspectos.

4 Metodologia

Nesta seção será apresentada a metodologia de pesquisa e experimentação. Na Seção 4.1 serão descritos os conjuntos de dados utilizados e nas Sessões 4.2, 4.3 e 4.4 e serão expostos detalhes sobre as métricas para avaliação, técnicas de extração utilizadas e os experimentos realizados, respectivamente.

4.1 Conjuntos de dados

Foi feita uma pesquisa por conjuntos de dados públicos para a realização de treinamento e teste de modelos para extração de características. A seguir, uma breve descrição sobre os conjuntos de dados encontrados.

4.1.1 *Fingerprint Verification Competition (FVC)*

Foram realizadas algumas competições organizadas por pesquisadores da *University of Bologna* para avaliação de sistemas de reconhecimento de usuários pela impressão digital. As partes A e B dos conjuntos de dados utilizados nas edições de 2000, 2002 e 2004 foram disponibilizadas publicamente como um material adicional da publicação de Maltoni et al. (2022).

Para cada ano da competição, há 4 conjuntos de dados, sendo 3 deles coletados com diferentes sensores e um quarto conjunto de impressões digitais sintéticas geradas através do software SFinGe (MALTONI et al., 2022). Cada um deles foi separados nas partes “A”, com imagens de 100 dedos, e “B”, com imagens de 10 dedos. Para cada dedo há 8 impressões digitais, totalizando 880 imagens em cada conjunto. Portanto, no total, o FVC possui $880 \times 4 \times 3 = 10560$ imagens.

4.1.2 Neurotechnology

A empresa Neurotechnology disponibilizou dois conjuntos de imagens de impressão digital, que podem ser acessados pelo site ⁴. O primeiro conjunto de dados possui imagens de 51 dedos com 8 impressões cada, totalizando 408 imagens capturadas com o leitor *Cross Match Verifier 300*. O segundo possui imagens de 65 dedos com 8 impressões cada, totalizando 520 imagens coletadas com o leitor *DigitalPersona U.are.U 4000*.

4.2 Métricas

Esta seção descreve algumas métricas usadas na literatura que serão usadas para avaliação dos resultados nos experimentos realizados neste projeto de pesquisa. Essas métricas são: FMR, FNMR e acurácia balanceada (Precise Biometrics, 2014; FERLINI et al., 2021). Uma breve descrição dessas métricas é apresentada a seguir:

- FMR (*False Match Rate*, Taxa de falsa correspondência): percentual de tentativas de impostores que foram aceitas como genuínas, definida como

$$FMR = \frac{\text{número de tentativas de impostores aceitas}}{\text{total de tentativas de impostores}}. \quad (1)$$

Uma taxa relacionada é a FAR (*False Acceptance Rate*), que tem significado similar, mas considera também taxa em que o sistema biométrico falha ao obter uma amostra biométrica. Essa taxa é conhecida como FTA (*Failure to Acquire Rate*).

- FNMR (*False Non-match Rate*, Taxa de falsa não-correspondência): percentual de tentativas genuínas que foram rejeitadas como impostoras pelo sistema, definida como

$$FNMR = \frac{\text{número de tentativas genuínas rejeitadas}}{\text{total de tentativas de usuários genuínos}}. \quad (2)$$

Uma métrica relacionada é a FRR (*False Rejection Rate*), que tem um significado similar, mas considera também a FTA.

- Acurácia balanceada: média do acerto para cada classe (genuíno e impostor). Essa métrica pode ser obtida a partir do cálculo da (HTER - *Half Total Error*, Metade do erro total)

⁴ <<https://www.neurotechnology.com/download.html>>

$$HTER = \frac{FNMR + FMR}{2}, \quad (3)$$

definida como a média entre FNMR e FMR (ROY et al., 2022). A partir da HTER, então é obtida a acurácia balanceada,

$$BAcc = 1 - HTER. \quad (4)$$

- EER (*Equal Error Rate, Taxa de erro igual*): ponto em que a FMR é igual a FNMR, em um determinado limiar de corte.

4.3 Algoritmos

Para os experimentos iniciais foram feitas buscas por repositórios com código-fonte disponíveis publicamente ou modelos pré-treinados que poderiam ter sido disponibilizados pelos autores dos artigos lidos na revisão bibliográfica. Foram feitos experimentos com o modelo DeepPrint implementado por Rohwedder et al. (2023), com o FLARE, implementado pelos próprios autores, e com a implementação do MCC disponível publicamente no Github⁵.

4.3.1 Arquitetura do *DeepPrint*

Engelsma, Cao e Jain (2021) desenvolveram uma Rede Neural Convolutacional (*Convolutional Neural Network* ou CNN) que “aprende” a extrair uma representação de tamanho fixo (um vetor) a partir de uma impressão digital. Como entrada a rede recebe uma imagem de tamanho 448×448 em escala de cinza (cada pixel assume um valor de 0 a 255) e passa primeiro pelo módulo de alinhamento. O módulo de alinhamento utiliza uma rede neural de transformação espacial (JADERBERG et al., 2016) para fazer com que a impressão digital na imagem fique no centro.

Em seguida, a imagem passa por uma rede base, que consiste na parte inicial da arquitetura *Inception* v4 (SZEGEDY et al., 2017), isso é, sem os módulos *Inception*. Neste ponto a rede é bifurcada em duas novas redes. A primeira completa a arquitetura da *Inception* v4 incluindo os módulos A, B e C, conforme descrito por Szegedy et al. (2017). O objetivo desta sub-rede é aprender a identificar impressões digitais com base apenas em sua textura (orientação dos

⁵ <<https://github.com/windhooked/MinutiaCylinderCode>>

cumes, formato da digital, etc), classificados por Maltoni et al. (2022) como atributos de nível 1, de nível global.

A segunda sub-rede possui um módulo A da arquitetura *Inception* v4, e também aprende a identificar impressões digitais com base em atributos globais. Entretanto, ela possui uma tarefa secundária de localizar as minúcias da digital e suas orientações, criando um mapa de minúcias, através de uma segunda CNN que também possui como base o módulo A. Esse compartilhamento de parâmetros entre a rede que classifica com base na textura, e a rede aprende a gerar o mapa de minúcias, classificado por Maltoni et al. (2022) como um atributo de nível 2, local e mais específico, melhora a capacidade de generalização da rede. Isso é uma técnica conhecida como Aprendizado Multitarefa (CARUANA; PRATT; THRUN, 1997).

Após a imagem de entrada passar por todas as camadas convolucionais, ela passa por camadas totalmente conectadas, e, em seguida, por funções de ativação *softmax*, para calcular a probabilidade de ela pertencer a cada uma das classes, em ambas as sub-redes. Com isso, os 96 pesos das camadas totalmente conectadas são concatenados para formarem um vetor de 192 dimensões. Em seguida os valores reais dos pesos são convertidos para inteiros utilizando normalização por mínimos e máximos. Dessa forma, é utilizada a similaridade de cossenos como medida de distância e um limiar de corte para verificação.




Figura 1 – Arquitetura do *DeepPrint*

4.3.2 Arquitetura do FLARE

O FLARE é um framework de identificação e verificação de impressões digitais baseado em uma rede neural profunda que foi treinada para extrair uma representação na forma de um tensor tridimensional após um pré-processamento que envolve alinhamento, realce e segmentação,

também realizados por redes neurais profundas treinadas de forma independente.

Inicialmente a imagem passa por uma etapa de alinhamento que utiliza duas técnicas complementares, uma baseada em regressão (GUAN et al., 2025) e outra baseada em votos (DUAN et al., 2023). A primeira faz uma estimativa da pose da digital com base no seu contorno da imagem enquanto a segunda infere com base em predições locais baseadas em representações densas das cristas. Pan et al. (2026) argumentam que o emprego de técnicas que aliam atributos globais e locais das digitais garante um alinhamento mais preciso.

Após o alinhamento, a imagem é realçada por dois modelos diferentes, o *UNetEnh* e o *PriorEnh*. A *UNetEnh* é uma rede neural convolucional baseada na arquitetura U-Net (RONNEBERGER; FISCHER; BROX, 2015) para segmentação e remoção de ruídos. A rede *PriorEnh*, por sua vez, desempenha o papel crítico de reconstruir parcialmente a estrutura das cristas em áreas severamente danificadas ou apagadas, utilizando para isso um conhecimento prévio sobre a geometria padrão de impressões digitais de boa qualidade.

Para a extração de características, Pan et al. (2026) desenvolveram a Rede de Representação Densa de Tamanho Fixo (*Fixed-length Dense Representation Network*, FDRN). A representação extraída por essa rede, diferente do *DeepPrint*, é uma representação tridimensional que codifica de forma mais natural a segmentação das impressões digitais, assim como as suas minúcias. Ela é baseada na arquitetura da rede ResNet-34 (HE et al., 2016), com a primeira camada de *Max Pooling* removida para preservação de detalhes mais finos impressões digitais. De forma semelhante ao que foi proposto em (ENGELSMA; CAO; JAIN, 2021), a rede é dividida em dois ramos para aprendizado multi-tarefa (CARUANA; PRATT; THRUN, 1997): a primeira sub-rede extrai um mapa de minúcias ao mesmo tempo que aprende a gerar uma representação de tamanho fixo que codifica informações sobre as minúcias; a segunda sub-rede extrai um mapa de segmentação que separa a impressão digital do fundo da imagem enquanto aprende a gerar uma representação de tamanho fixo com base nos padrões dos cumes da digital. Ambas as sub-redes incluem um módulo de incorporação posicional senoidal (VASWANI et al., 2017) para melhorar a capacidade de distinção das representações.

A representação final é obtida ao concatenar os resultados de ambas as sub-redes e calcular o produto de Hadamard com os tensores concatenados e a máscara de segmentação. Sendo f_s e f_m os descritores de textura e minúcia, respectivamente, e S a máscara de segmentação, o descritor final de tamanho fixo é obtido a partir da expressão $f = (f_s \oplus f_m) \odot S$.

Pan et al. (2026) explica que representações densas multidimensionais detém uma capacidade

descritiva superior a representações unidimensionais, como a que é extraída pelo *DeepPrint*. Os autores sugerem que essa agregação global em um único vetor global abstrato faz com que os modelos percam informações estruturais e geométricas cruciais sobre a organização das cristas da impressão digital. Além disso, os vetores de características unidimensionais são vulneráveis a interferências, pois não modelam ou suprimem de forma explícita as áreas de fundo (*background*) no nível do descritor. Isso pode prejudicar a precisão de correspondência quando há fortes ruídos ou quando a área de captura da digital varia muito, como ocorre em impressões parciais ou de baixa qualidade.

No processo de verificação entre uma digital de consulta (*query*) e uma de referência (*gallery*), os descritores tridimensionais e suas máscaras são achatados em vetores unidimensionais para a realização das comparações matriciais⁵. A pontuação de similaridade $M_i(q, g)$ para cada par de imagens é calculada pela fórmula do cosseno normalizado $M_i(q, g) = \frac{f_q'^T \cdot f_g'}{\|f_q \odot S_g\|_F \cdot \|f_g \odot S_q\|_F}$ ⁶. No numerador, a multiplicação matricial do vetor transposto de consulta pelo vetor de referência ($f_q'^T \cdot f_g'$) realiza o produto escalar das características apenas nas regiões onde ambas as impressões possuem primeiro plano válido, visto que o fundo de cada imagem já foi previamente anulado pela sua respectiva máscara⁴⁶. No denominador, o produto de Hadamard cruzado ($f_q \odot S_g$ e $f_g \odot S_q$) filtra o descritor de uma imagem utilizando a máscara da outra, isolando estritamente a área de intersecção espacial compartilhada entre elas. Em seguida, a norma de Frobenius ($\|\cdot\|_F$) calcula a magnitude desse tensor resultante na região sobreposta, atuando como o fator de normalização da similaridade de cosseno para evitar distorções causadas por variações no tamanho da área de contato.




Figura 2 – Arquitetura do FLARE

4.3.3 Representação baseada em Cilindros

O *Minutia Cylinder-Code* (MCC) é uma representação local tridimensional projetada para codificar as relações espaciais e direcionais entre uma minúcia central e suas vizinhas dentro de uma região de raio fixo. A cada minúcia é associada uma estrutura em formato de cilindro, cuja base possui raio R e cuja altura engloba todo o intervalo de orientação de 2π . Como a base do cilindro é posicionada sobre a localização da minúcia e rotacionada conforme a sua direção, a representação garante invariância à translação e à rotação. O espaço tridimensional do cilindro é discretizado em uma grade regular de células⁴. Cada célula reflete uma posição espacial e uma diferença angular específica em relação à minúcia central.

O valor numérico atribuído a cada célula indica a probabilidade de existirem minúcias vizinhas naquela posição e orientação. Esse valor é determinado pelo acúmulo das contribuições das minúcias vizinhas, combinando uma contribuição espacial (calculada via função gaussiana baseada na distância euclidiana) e uma contribuição direcional (também derivada de uma função gaussiana aplicada à diferença angular). Para suavizar ruídos, distorções do tecido cutâneo e pequenas imprecisões de extração, a soma das contribuições é submetida a uma função sigmóide que limita os valores ao intervalo. Além disso, aplica-se uma máscara de validade baseada na envoltória convexa (*convex hull*) das minúcias para desconsiderar células localizadas fora da região útil da impressão digital¹¹.

Para comparar duas impressões digitais, as similaridades locais entre os cilindros são combinadas em uma pontuação de similaridade global. Métodos diretos, como a Ordenação de Similaridade Local (LSS) e a Atribuição de Similaridade Local (LSA), selecionam e tiram a média dos pares de cilindros mais semelhantes, sendo que a LSA utiliza o algoritmo húngaro para evitar a associação duplicada de uma mesma minúcia. Para maior precisão, o processo pode incluir uma etapa de relaxamento (LSS-R e LSA-R), que reavalia iterativamente cada similaridade local com base na compatibilidade geométrica global (distâncias espaciais, diferenças direcionais e ângulos radiais) com outros pares de minúcias.

4.4 Experimentos

Foram realizados experimentos com modelos pré-treinados do DeepPrint e do FLARE. O modelo do DeepPrint foi disponibilizado por Rohwedder et al. (2023), que pode ser obtido através do link⁶. O repositório com o código-fonte utilizado para o treinamento do modelo está disponível

⁶ <https://drive.google.com/file/d/1R9v73hFBuy0iiz7v8eDIBcGrMDmQ9TH/view?usp=drive_link>

publicamente no GitHub⁷.

No caso do FLARE foram disponibilizados modelos pré-treinados para cada um dos módulos do framework: dois modelos para as redes de alinhamento e estimativa de pose, dois para as redes de realce e um para a rede de extração de representação densa. O código utilizado para o treinamento dos modelos está disponível em publicamente no Github⁸. A seguir serão descritos como foi feito treinamento o do modelo e os testes realizados.

4.4.1 Treinamento do DeepPrint

Engelsma, Cao e Jain (2021) utilizaram o conjunto de dados longitudinal (YOON; JAIN, 2015) de cerca de 455000 imagens de 38291 dedos, que não está disponível publicamente. Os autores não disponibilizaram nenhum código-fonte ou modelo pré-treinado. Dessa forma, optamos por utilizar a implementação da arquitetura do DeepPrint e modelo pré-treinado de Rohwedder et al. (2023), que tinha como objetivo avaliar o desempenho preditivo do modelo em imagens coletadas com outros tipos de sensores e com representações de tamanhos diferentes.

Com o intuito de eliminar a necessidade de coletar impressões digitais ou de utilizar um conjunto de dados público os autores utilizaram o SFinGe (MALTONI et al., 2022) para a criação de impressões digitais sintéticas. Para o treinamento, foram utilizadas 10 impressões digitais de 6000 indivíduos, e para validação 4 imagens de 2000 indivíduos, totalizando 68000 imagens. A partir deste banco de imagens foram geradas novas imagens aplicando-se rotações, reflexões e variações de brilho e contraste de forma aleatória, assim como no artigo original. Uma outra diferença em relação ao experimento de Engelsma, Cao e Jain (2021) foi o tamanho da representação. O modelo pré-treinado gera representações de 512 dimensões, com 256 de dimensões em cada sub-rede.

4.4.2 Treinamento do FLARE

Em (PAN et al., 2026) é explicado como cada um dos módulos do *framework* FLARE foi treinado, e quais conjuntos de imagens foram utilizados em cada etapa do treinamento. Nesta seção será descrito brevemente o processo de treinamento das redes neurais que compõem o FLARE.

Os módulos de alinhamento por regressão global direta (GUAN et al., 2025) e votação local densa (DUAN et al., 2023) foram treinados seguindo os métodos originalmente descritos por seus respectivos autores. Foram utilizadas imagens do conjunto de dados do *Diverse Pose Fingerprint*

⁷ <<https://github.com/tim-rohwedder/fixed-length-fingerprint-extractors>>

⁸ <<https://github.com/Yu-Yy/FLARE>>

(DPF) e as primeiras 3200 imagens do NIST SD14. Para tornar a rede de alinhamento tolerante a ruídos de fundo foi empregada uma estratégia de aumento de dados que insere de forma aleatória padrões de interferência extraídos do conjunto de imagens MSRA-TD500.

Para o treinamento da *UNetEhn* também foi treinada utilizando imagens de alta resolução e suas respectivas cópias com desfoque gaussiano, padrões de linhas, caracteres manuscritos do MNIST e sobreposições de fundo do conjunto de dados BID. Já o treinamento da rede PriorEnh é estruturado em duas etapas independentes e consecutivas. Primeiro, um *autoencoder* variacional quantizado vetorial (VQ-VAE)(OORD; VINYALS; KAVUKCUOGLU, 2017) é treinado de forma não supervisionada para auto-reconstruir imagens de alta qualidade do DPF. Através deste processo de aprendizado discreto, a rede cria um dicionário latente (C) composto por 4096 códigos com dimensão de incorporação (d_c) igual a 33. Esse codebook funciona como uma biblioteca geométrica que armazena estruturas de cristas limpas e regulares.

Na segunda etapa de treinamento da PriorEnh, o dicionário de padrões geométricos e o decodificador obtidos na fase anterior são congelados. Em seguida, um codificador seguindo a arquitetura do U-Net, um indexador *GatedPixelCNN*(OORD et al., 2016) e um módulo de transformação de características (CFT)(WANG et al., 2018) são treinados conjuntamente para receber imagens com degradações simuladas e reconstruir suas versões limpas de alta qualidade.

Para o treinamento da FDRN foram utilizados os primeiros 24000 pares de impressões digitais de alta qualidade do NIST SD14 e 2.676 impressões planas de 633 dedos distintos, juntamente com suas respectivas máscaras de segmentação, foram selecionadas do DPF com o intuito de simular impressões digitais incompletas e parciais por meio da aplicação de máscaras binárias.

4.4.3 Testes com os modelos pré-treinados

Foram realizados testes utilizando todos os conjuntos de dados do FVC e Neurotechnology. Foi calculada uma matriz de pontuação completa entre cada imagem de consulta (*query*) e cada imagem de galeria (*gallery*) (imagem a imagem, sem agregação por sujeito e sem amostragem aleatória). Cada par (*query*, *gallery*) torna-se uma comparação, sendo considerado correspondente quando ambas as amostras pertencem ao mesmo dedo. Para todos os conjuntos de dados foram incluídas na *query* as primeiras 4 imagens de cada dedo, e no conjunto *gallery* as últimas 4 imagens de cada dedo.

Para calcular a FNMR, FMR e EER é necessário definir um limiar de corte que a pontuação deve atingir. Os limiares de cortes foram selecionados diretamente das pontuações de cada

comparação. Foram considerados 1000 valores igualmente espaçados do intervalo cujos extremos são a pontuação mínima e máxima obtida em cada conjunto de dados, para cada técnica de extração utilizado.

5 Resultados e discussão dos resultados

Esta seção apresenta os resultados obtidos nos experimentos de verificação biométrica com os modelos DeepPrint e FLARE (e suas respectivas variações de alinhamento e realce) sobre as partições de avaliação principal (Parte A) dos sensores reais (DB1 a DB3) das edições FVC2000, FVC2002 e FVC2004, bem como sobre os conjuntos de dados CrossMatch e U.are.U disponibilizados pela Neurotechnology.

A Tabela 2 apresenta a comparação de EER obtida pelas arquiteturas base (sem realce) no ponto de mínima diferença entre FAR e FRR. As Tabelas 3 e 4 detalham o efeito das etapas de realce (PriorEnh e UNetEnh) sobre o desempenho do DeepPrint e do FLARE (alinhamento por regressão e votação), respectivamente.

Tabela 2 – EER (%) das arquiteturas base (sem realce) nos subconjuntos Parte A do FVC e nas bases da Neurotechnology.

Edição / Origem	Base	DeepPrint	FLARE (Reg.)	FLARE (Vot.)
FVC2000	DB1-A	3.36	0.81	0.81
	DB2-A	2.69	0.54	0.19
	DB3-A	3.85	0.63	0.59
Média FVC2000		3.30	0.66	0.53
FVC2002	DB1-A	5.20	0.44	0.25
	DB2-A	8.19	0.62	0.69
	DB3-A	8.51	3.32	2.08
Média FVC2002		7.30	1.46	1.01
FVC2004	DB1-A	17.05	0.25	0.24
	DB2-A	5.27	1.44	0.87
	DB3-A	4.91	0.38	0.31
Média FVC2004		9.08	0.69	0.47
Média FVC		6.56	0.94	0.67
Neurotechnology	CrossMatch	3.31	0.49	0.12
	U.are.U	2.76	0.58	0.86
Média Neurotechnology		3.04	0.53	0.49
Média Geral		5.92	0.86	0.64

A Figura 3 apresenta a comparação da distribuição dos pontuações de similaridade entre o modelo DeepPrint e o modelo FLARE (com alinhamento por votação) para os conjuntos DB1-A

Tabela 3 – EER (%) do DeepPrint com métodos de realce nos subconjuntos Parte A do FVC e nas bases da Neurotechnology.

Edição / Origem	Base	Original	PriorEnh	UNetEnh
FVC2000	DB1-A	3.36	12.45	4.66
	DB2-A	2.69	3.41	2.88
	DB3-A	3.85	3.51	3.78
Média FVC2000		3.30	6.46	3.77
FVC2002	DB1-A	5.20	5.10	5.29
	DB2-A	8.19	7.15	6.84
	DB3-A	8.51	9.70	8.66
Média FVC2002		7.30	7.32	6.93
FVC2004	DB1-A	17.05	16.69	17.00
	DB2-A	5.27	5.10	5.27
	DB3-A	4.91	5.01	5.54
Média FVC2004		9.08	8.93	9.27
Média FVC		6.56	7.57	6.66
Neurotechnology	CrossMatch	3.31	3.31	3.28
	U.are.U	2.76	3.04	2.99
Média Neurotechnology		3.04	3.17	3.13
Média Geral		5.92	6.77	6.02

Tabela 4 – EER (%) do FLARE com métodos de realce nos subconjuntos Parte A do FVC e nas bases da Neurotechnology.

Edição / Origem	Base	FLARE (Regressão)			FLARE (Votação)		
		Base	Prior	UNet	Base	Prior	UNet
FVC2000	DB1-A	0.81	7.13	1.06	0.81	8.02	0.87
	DB2-A	0.54	0.56	0.37	0.19	0.24	0.19
	DB3-A	0.63	0.93	0.87	0.59	0.57	0.64
Média FVC2000		0.66	2.87	0.77	0.53	2.94	0.57
FVC2002	DB1-A	0.44	0.56	0.68	0.25	0.31	0.25
	DB2-A	0.62	0.62	0.56	0.69	0.82	0.31
	DB3-A	3.32	4.14	3.00	2.08	3.05	2.12
Média FVC2002		1.46	1.77	1.41	1.01	1.39	0.89
FVC2004	DB1-A	0.25	0.69	0.25	0.24	0.44	0.31
	DB2-A	1.44	1.38	1.48	0.87	1.19	1.31
	DB3-A	0.38	0.50	1.26	0.31	0.57	1.26
Média FVC2004		0.69	0.86	1.00	0.47	0.73	0.96
Média FVC		0.94	1.83	1.06	0.67	1.69	0.81
Neurotechnology	CrossMatch	0.49	0.73	0.86	0.12	0.12	0.25
	U.are.U	0.58	0.51	0.58	0.86	0.95	1.06
Média Neurotechnology		0.53	0.62	0.72	0.49	0.53	0.66
Média Geral		0.86	1.61	1.00	0.64	1.48	0.78


a DB4-A da edição FVC2000. Observa-se que no FLARE a distribuição dos pontuações de impostores (vermelho) permanece concentrada em valores baixos (próximos a 0,2), resultando em uma separação quase total em relação aos usuários genuínos (verde) e justificando as taxas de EER substancialmente menores em comparação ao DeepPrint.

A Figura 4 apresenta a comparação dos pontuações entre o DeepPrint e o FLARE (alinhamento por votação) para os conjuntos CrossMatch e U.are.U da Neurotechnology. Observa-se comportamento análogo ao verificado no FVC: o FLARE exibe pontuações de impostores bastante concentrados em valores inferiores a 0,25 e genuínos acima de 0,45, conferindo EER de 0,12% no CrossMatch e 0,86% no U.are.U, enquanto o DeepPrint apresenta distribuições com maior proximidade entre as classes (EER de 3,31% e 2,76%, respectivamente).


Em relação ao impacto dos métodos de realce sobre a capacidade discriminativa das representações (Tabelas 3 e 4), observa-se que a UNetEnh preserva de maneira consistente o desempenho em ambos os modelos, mantendo taxas de EER próximas às das arquiteturas base. Por outro lado, o uso da PriorEnh provoca aumento expressivo do EER em determinadas bases com maior presença de ruído, como no DB1-A do FVC2000 (com 12,45% no DeepPrint e 8,02% no FLARE), embora no DB2-A o FLARE mantenha elevada separação (0,24%). Já nas bases da Neurotechnology, devido à boa qualidade intrínseca das capturas por sensores de alta resolução, tanto a PriorEnh quanto a UNetEnh preservam a estabilidade das representações, mantendo os índices de EER do FLARE em níveis inferiores a 1,1% e os do DeepPrint em torno de 3,0% a 3,3%.

6 Conclusões e perspectivas de trabalhos futuros


Este trabalho apresentou uma avaliação comparativa de técnicas de extração de características de comprimento fixo baseadas em aprendizado profundo para verificação biométrica por impressões digitais, contrastando as arquiteturas *DeepPrint* e *FLARE* nas edições FVC2000, FVC2002, FVC2004 e nas bases ópticas da Neurotechnology. Os resultados comprovaram a superioridade das representações densas tridimensionais frente a vetores unidimensionais: o FLARE com alinhamento por votação alcançou uma taxa média geral de EER de 0,64%, contra 5,92% do DeepPrint. Esse ganho decorre da preservação da topologia local das cristas e da supressão explícita de ruídos de fundo por meio de máscaras de segmentação na representação 3D, contrastando com as perdas de informação espacial inerentes à compressão em um vetor global.




(a) DeepPrint - DB1-A




(b) FLARE (Votação) - DB1-A




(c) DeepPrint - DB2-A




(d) FLARE (Votação) - DB2-A




(e) DeepPrint - DB3-A



(f) FLARE (Votação) - DB3-A



(g) DeepPrint - DB4-A



(h) FLARE (Votação) - DB4-A

Figura 3 – Comparação da distribuição dos pontuações de similaridade entre DeepPrint (coluna à esquerda) e FLARE com alinhamento por votação (coluna à direita) para os subconjuntos DB1-A a DB4-A do FVC2000.




Figura 4 – Comparação da distribuição dos pontuações de similaridade entre DeepPrint (coluna à esquerda) e FLARE com alinhamento por votação (coluna à direita) para os conjuntos CrossMatch e U.are.U da Neurotechnology.

A análise dos módulos revelou que a estimativa de alinhamento por votação densa superou consistentemente a predição direta por regressão no FLARE, conferindo maior estabilidade frente a distorções e impressões parciais. Quanto ao realce de imagem, a rede UNetEnh atuou de forma consistente e segura, preservando os níveis de EER das imagens brutas em ambos os modelos. Em contrapartida, a rede generativa PriorEnh induziu degradações severas em bases com forte ruído de fundo (como no FVC2000 DB1-A, no qual o EER subiu de 3,36% para 12,45% no DeepPrint e de 0,81% para 8,02% no FLARE), demonstrando que a reconstrução sintética de cristas pode introduzir artefatos e minúcias espúrias, embora em sensores ópticos de alta qualidade ambas as abordagens tenham mantido elevada fidelidade.

Como perspectivas de trabalhos futuros, destaca-se a investigação de abordagens conjuntas (*end-to-end*) que treinem simultaneamente as etapas de realce, alinhamento e extração densa, mitigando a propagação de erros entre módulos independentes.

Referências

CAPPELLI, R.; FERRARA, M.; MALTONI, D. Minutia cylinder-code: A new representation and matching technique for fingerprint recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 32, p. 2128–2141, 2010. ISSN 01628828.

CARUANA, R.; PRATT, L.; THRUN, S. *Multitask Learning*. [S.l.], 1997. v. 28, 41-75 p.

DUAN, Y.; FENG, J.; LU, J.; ZHOU, J. Estimating fingerprint pose via dense voting. *Trans. Info. For. Sec.*, IEEE Press, v. 18, p. 2493–2507, jan. 2023. ISSN 1556-6013. Disponível em: <<https://doi.org/10.1109/TIFS.2023.3266625>>.

ENGELSMA, J. J.; CAO, K.; JAIN, A. K. Learning a fixed-length fingerprint representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, IEEE Computer Society, v. 43, p. 1981–1997, 6 2021. ISSN 19393539.

EZEGBIEJESI, J.; BHANU, B. Latent fingerprint image segmentation using deep neural network. In: _____. *Advances in Computer Vision and Pattern Recognition*. [S.l.]: Springer London, 2017. PartF1, p. 83–107.

FERLINI, A.; MA, D.; HARLE, R.; MASCOLO, C. Eargate: gait-based user identification with in-ear microphones. In: . New York, NY, USA: Association for Computing Machinery, 2021. (MobiCom '21), p. 337–349. ISBN 9781450383424.

GUAN, X.; PAN, Z.; FENG, J.; ZHOU, J. Finger pose estimation for under-screen fingerprint sensor. *IEEE Transactions on Information Forensics and Security*, v. 20, p. 12739–12753, 2025.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep Residual Learning for Image Recognition . In: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Los Alamitos, CA, USA: IEEE Computer Society, 2016. p. 770–778. ISSN 1063-6919. Disponível em: <<https://doi.ieeecomputersociety.org/10.1109/CVPR.2016.90>>.

JADERBERG, M.; SIMONYAN, K.; ZISSERMAN, A.; KAVUKCUOGLU, K. Spatial transformer networks. 2 2016. Disponível em: <<http://arxiv.org/abs/1506.02025>>.

JAIN, A.; FLYNN, P.; ROSS, A. *Handbook of Biometrics*. [S.l.]: Springer US, 2007. ISBN 9780387710419.

JAIN, A.; ROSS, A.; PANKANTI, S. Biometrics: a tool for information security. *IEEE Transactions on Information Forensics and Security*, v. 1, n. 2, p. 125–143, 2006.

JAIN, A.; ROSS, A.; PRABHAKAR, S. An introduction to biometric recognition. *IEEE Transactions on Circuits and Systems for Video Technology*, IEEE, v. 14, n. 1, p. 4–20, 2004. ISSN 1051-8215.

LEVI, G.; SIROVICH, F. Structural descriptions of fingerprint images. *Information Sciences*, v. 4, n. 3, p. 327–355, 1972. ISSN 0020-0255. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0020025572800203>>.

LI, R.; SONG, D.; LIU, Y.; FENG, J. Learning global fingerprint features by training a fully convolutional network with local patches. In: *2019 International Conference on Biometrics (ICB)*. [S.l.: s.n.], 2019. p. 1–8.

MALTONI, D.; MAIO, D.; JAIN, A. K.; FENG, J. Book. *Handbook of fingerprint recognition: Third edition*. [s.n.], 2022. 1 - 522 p. Cited by: 42. Disponível em: <<https://www.scopus.com/inward/record.uri?eid=2-s2.0-85159134415&doi=10.1007%2f978-3-030-83624-5&partnerID=40&md5=20c90152518eac119f092021f0fe4dfa>>.

MOENSSSENS, A. *Fingerprint Techniques*. Chilton Book Company, 1971. (Inbau law enforcement series). ISBN 9780801955273. Disponível em: <<https://books.google.com.br/books?id=aF6qQgAACAAJ>>.

NGUYEN, D. L.; CAO, K.; JAIN, A. K. Robust minutiae extractor: Integrating deep networks and fingerprint domain knowledge. In: *Proceedings - 2018 International Conference on Biometrics, ICB 2018*. [S.l.]: Institute of Electrical and Electronics Engineers Inc., 2018. p. 9–16. ISBN 9781538642856.

OORD, A. v. d.; KALCHBRENNER, N.; VINYALS, O.; ESPEHOLT, L.; GRAVES, A.; KAVUKCUOGLU, K. Conditional image generation with pixelcnn decoders. In: *Proceedings of the 30th International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2016. (NIPS'16), p. 4797–4805. ISBN 9781510838819.

OORD, A. van den; VINYALS, O.; KAVUKCUOGLU, K. Neural discrete representation learning. In: *Proceedings of the 31st International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2017. (NIPS'17), p. 6309–6318. ISBN 9781510860964.

PAN, Z.; GUAN, X.; DUAN, Y.; FENG, J.; ZHOU, J. Fixed-length dense fingerprint representation with alignment and robust enhancement. *IEEE Transactions on Information Forensics and Security*, IEEE, 2026.

Precise Biometrics. *Understanding Biometric Performance Evaluation*. 2014. Disponível em: <<http://precisebiometrics.com/wp-content/uploads/2014/11/White-Paper-Understanding-Biometric-Performance-Evaluation.pdf>>.

ROHWEDDER, T.; OSORIO-ROIG, D.; RATHGEB, C.; BUSCH, C. Benchmarking fixed-length fingerprint representations across different embedding sizes and sensor types. In: *BIOSIG 2023 - Proceedings of the 22nd International Conference of the Biometrics Special Interest Group*. [S.l.]: Institute of Electrical and Electronics Engineers Inc., 2023. ISBN 9798350336559.

RONNEBERGER, O.; FISCHER, P.; BROX, T. U-net: Convolutional networks for biomedical image segmentation. In: NAVAB, N.; HORNEGGER, J.; WELLS, W. M.; FRANGI, A. F. (Ed.). *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*. Cham: Springer International Publishing, 2015. p. 234–241. ISBN 978-3-319-24574-4.

ROY, S.; PRADHAN, J.; KUMAR, A.; ADHIKARY, D. R. D.; ROY, U.; SINHA, D.; PAL, R. K. A systematic literature review on latest keystroke dynamics based models. *IEEE Access*, v. 10, p. 92192–92236, 2022.

SZEGEDY, C.; IOFFE, S.; VANHOUCKE, V.; ALEMI, A. Inception-v4, inception-resnet and the impact of residual connections on learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, v. 31, n. 1, Feb. 2017. Disponível em: <<https://ojs.aaai.org/index.php/AAAI/article/view/11231>>.

TANG, Y.; GAO, F.; FENG, J. Latent fingerprint minutia extraction using fully convolutional network. In: *2017 IEEE International Joint Conference on Biometrics (IJCB)*. [S.l.: s.n.], 2017. p. 117–123.

TANG, Y.; GAO, F.; FENG, J.; LIU, Y. Fingernet: An unified deep network for fingerprint minutiae extraction. In: *2017 IEEE International Joint Conference on Biometrics (IJCB)*. [S.l.: s.n.], 2017. p. 108–116.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. In: *Proceedings of the 31st International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2017. (NIPS'17), p. 6000–6010. ISBN 9781510860964.

WANG, X.; YU, K.; DONG, C.; LOY, C. C. Recovering realistic texture in image super-resolution by deep spatial feature transform. In: *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. [S.l.: s.n.], 2018. p. 606–615.

YOON, S.; JAIN, A. K. Longitudinal study of fingerprint recognition. *Proceedings of the National Academy of Sciences*, v. 112, n. 28, p. 8555–8560, 2015. Disponível em: <<https://www.pnas.org/doi/abs/10.1073/pnas.1410272112>>.

ZHANG, F.; XIN, S.; FENG, J. Combining global and minutia deep features for partial high-resolution fingerprint matching. *Pattern Recognition Letters*, v. 119, p. 139–147, 2019. ISSN 0167-8655. Deep Learning for Pattern Recognition. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0167865517303227>>.