



Fundação Universidade Federal do ABC

Pró reitoria de pesquisa

Av. dos Estados, 5001, Santa Terezinha, Santo André/SP, CEP 09210-580

Bloco L, 3ºAndar, Fone (11) 3356-7617

iniciacao@ufabc.edu.br

Relatório Final de Iniciação Científica
referente ao Edital: 01/2025

Nome do aluno: Thiago Fernandes Dias

Assinatura do aluno:

Nome do orientador: Paulo Henrique Pisani

Assinatura do orientador:

Nome do coorientador: Francisco de Assis Zampirolli

Assinatura do coorientador:

Título do projeto: Avaliação de técnicas de extração de características para reconhecimento de usuários pela impressão digital

Palavras-chave do projeto: biometria; aprendizado de máquina; classificação

Área do conhecimento do projeto: Ciências Exatas e da Terra; Ciência da Computação; Metodologia e Técnicas da Computação

Bolsista: Sim, CNPq

Santo André

2026

Resumo

Este trabalho apresenta uma avaliação comparativa de técnicas de extração de características para verificação biométrica por impressões digitais, contrastando as arquiteturas de aprendizado profundo *DeepPrint* (vetor unidimensional de tamanho fixo) e *FLARE* (descriptor denso tridimensional com alinhamentos por regressão e votação) com o método clássico *Minutia Cylinder-Code* (MCC). Os experimentos foram conduzidos sobre os subconjuntos Parte A das competições FVC2000, FVC2002 e FVC2004, além das bases ópticas CrossMatch e U.are.U da Neurotechnology, avaliando-se as taxas FMR , $FNMR$ e a EER no ponto de mínima diferença. Os resultados indicam a superioridade expressiva do FLARE, que obteve EER média geral de 0,64% na abordagem por votação, beneficiado pela preservação de relações espaciais e supressão explícita de fundo. O DeepPrint alcançou EER média de 5,92%, apresentando maior sensibilidade a ruídos severos. O MCC obteve desempenho competitivo em bases ópticas de alta qualidade (EER média de 2,02% na Neurotechnology e 2,69% no FVC2000 DB1-A), superando o DeepPrint nesses cenários, porém com degradação em amostras ruidosas. Por fim, constatou-se que o emprego de etapas prévias de realce (UNetEnh e PriorEnh) não resultou em aprimoramentos consistentes de desempenho nas arquiteturas avaliadas.

Sumário

1	Introdução	4
2	Fundamentação teórica	5
2.1	Biometria por Impressão Digital	5
2.2	Formas de representação de impressões digitais	6
2.3	Extração de características de digitais	6
3	Objetivos	9
4	Metodologia	10
4.1	Conjuntos de dados	10
4.1.1	<i>Fingerprint Verification Competition</i> (FVC)	10
4.1.2	Neurotechnology	10
4.2	Métricas	11
4.3	Algoritmos	11
4.3.1	Arquitetura do <i>DeepPrint</i>	11
4.3.2	Arquitetura do FLARE	12
4.3.3	Representação baseada em Cilindros	14
4.4	Experimentos	14
4.4.1	Treinamento do <i>DeepPrint</i>	15
4.4.2	Treinamento do FLARE	15
4.4.3	Extração dos mapas de minúcias com o <i>FingerNet</i> para os testes com o MCC	16
4.4.4	Testes com os modelos pré-treinados do FLARE e <i>DeepPrint</i> e implementação do MCC	16
5	Resultados e discussão dos resultados	17
6	Conclusões e perspectivas de trabalhos futuros	18
	REFERÊNCIAS	19

1 Introdução

A Biometria é uma forma de identificação que se baseia nas características físicas ou comportamentais das pessoas, como íris, impressões digitais e voz. Sistemas biométricos operam sobre a premissa de que tais características são únicas para cada indivíduo, e, se puderem ser extraídas através de sensores, podem ser convertidas para representações numéricas e processadas por algoritmos de reconhecimento de padrões (JAIN; FLYNN; ROSS, 2007). Como os dados biométricos são particulares a cada pessoa, eles podem ser usados como forma de autenticação e de forma mais segura do que o uso de senhas (JAIN; ROSS; PANKANTI, 2006).

Neste projeto, será dado enfoque à vertente física, em particular, na biometria através de impressões digitais. Essa modalidade biométrica se baseia nos padrões de pequenas elevações e depressões na pele das pontas dos dedos (MALTONI et al., 2022). Os usuários são então reconhecidos com base nas diferenças nesses padrões.

Conforme definido por Jain, Ross e Prabhakar (2004), sistemas biométricos são sistemas de reconhecimento de padrões que extraem características de dados biométricos e então compararam as características extraídas com uma referência biométrica em um banco de dados. Nesse sentido, Maltoni et al. (2022) explicam que, para a autenticação através de impressões digitais, a representação das características extraídas das imagens é um problema fundamental da verificação de digitais.

Como não há a garantia de que as imagens da impressão digital de um mesmo dedo serão exatamente iguais em termos de intensidade de pixel, ruídos de fundo, orientação e formato, há a necessidade de se extrair características a partir das quais seja possível diferenciar digitais com uma boa acurácia e que sejam invariantes para uma dada digital. Somente assim o uso de digitais em sistemas de autenticação se tornaria viável.

O objetivo deste trabalho é avaliar diferentes técnicas de extração de características para reconhecimento de usuários pela impressão digital. As demais seções do relatório estão organizadas da seguinte forma: na Seção 2, são introduzidos conceitos sobre reconhecimento de usuários pela impressão digital e a revisão bibliográfica realizada; na Seção 3, são definidos os objetivos; na Seção 4, a metodologia é descrita, incluindo conjuntos de dados e métricas; na Seção 5, são exibidos os resultados obtidos e na Seção 6, é feita a conclusão do relatório.

2 Fundamentação teórica

Esta seção apresenta algumas constatações sobre a pesquisa na área de impressões digitais e técnicas de extração de características.

2.1 Biometria por Impressão Digital

O termo “Impressão Digital” no contexto de biometria por impressões digitais se refere ao padrão de pequenos cumes e vales que podem ser observados na ponta dos dedos das pessoas. Ao longo da evolução da espécie humana, o desenvolvimento de digitais está relacionado à capacidade de segurar objetos com as mãos. O padrão específico de cumes e vales, assim como outras características do corpo, é definido por fatores genéticos e ambientais (MALTONI et al., 2022).

O reconhecimento de que as impressões digitais são únicas para cada dedo de cada pessoa ocorreu em 1880 com base em observações experimentais de Henry Faulds (MOENSSENS, 1971). Algum tempo depois, a unicidade de impressões digitais foi reconhecida por entidades governamentais do Reino Unido, e foi determinado que as digitais de criminosos seriam coletadas no momento da prisão. Assim, seria possível identificar pessoas a partir de impressões digitais coletadas em cenas de crime a partir da análise feita por especialistas em investigação forense. Conforme explica Maltoni et al. (2022), apesar dos esforços para tornar mais eficiente o processo manual de identificação por impressões digitais, o aumento da demanda tornou esse método inviável. O sistema de classificação manual era ineficiente, o treinamento de novos profissionais capazes de empregá-lo era demorado e a comparação visual de impressões digitais era cansativa e lenta. Por isso, os órgãos de segurança pública começaram a investir em soluções eletrônicas e automatizadas, o que levou ao desenvolvimento dos Sistemas Automatizados de Identificação de Impressões Digitais (*Automated Fingerprint Identification Systems* - AFIS).

Inicialmente usados por forças de segurança, esses sistemas hoje também são aplicados em diversas áreas não forenses devido ao aumento das preocupações com segurança e fraudes de identidade. Por exemplo, sistemas biométricos têm sido adotados em *Internet Banking* e autenticação de usuários em dispositivos móveis. Nesse contexto, as digitais são coletadas com sensores especializados que geram imagens das impressões digitais, que são processadas a fim de se obter uma forma de representação que pode ser usada para verificação (MALTONI et al., 2022).

2.2 Formas de representação de impressões digitais

Maltoni et al. (2022) enfatiza que uma boa representação de uma impressão digital deve: (i) conter informações que possibilitem distinguir entre duas amostras; (ii) ser extraída de forma rápida e fácil; e (iii) ser compacta, de modo a poder ser armazenada em sistemas biométricos com pouca capacidade. Representações baseadas em imagens, em geral, não são adequadas devido às variações de iluminação, resolução, qualidade e aos ruídos provocados por cicatrizes ou outras lesões nos dedos, especialmente em pessoas que realizam trabalhos manuais com frequência.

2.3 Extração de características de digitais

Com o objetivo de selecionar os métodos que seriam avaliados neste projeto, foi feita uma revisão bibliográfica sobre artigos que descreviam métodos de extração que, preferencialmente, utilizassem algoritmos de Aprendizado de Máquina e que utilizassem conjuntos de dados públicos para treinamento e teste dos modelos, para facilitar a reprodutibilidade.

Na Tabela 1 há alguns dos artigos lidos e as técnicas de extração de características propostas.

Tabela 1 – Revisão Bibliográfica

Referência	Conjunto de dados	Métricas	Código aberto
Cappelli, Ferrara e Maltoni (2010)	FVC2006	<i>EER</i> , <i>FMR</i>	Sim
Nguyen, Cao e Jain (2018)	FVC2002, FVC2004, NIST SD27	F1 Score, Precisão, <i>Recall</i>	Sim
Engelsma, Cao e Jain (2021)	Privado, NIST SD4, NIST SD14, FVC2004	<i>Acc</i> , <i>FMR</i>	Sim
Ezeobijesi e Bhanu (2017)	NIST SD27, WVU, IIITD	MDR, FDR, SA	Não
Tang, Gao e Feng (2017)	Privado, NIST SD27	<i>Recall</i> , Precisão, F1 Score	Não
Tang et al. (2017)	Privado, NIST SD27	Precisão, <i>Recall</i>	Sim
Zhang, Xin e Feng (2019)	Privado, FVC2002, FVC2004	<i>EER</i> , <i>FMR</i> , <i>FNMR</i>	Não
Li et al. (2019)	Privado, NIST SD4, NIST SD14	Top-K ER	Não

Tabela 1 – Revisão Bibliográfica

Referência	Conjunto de dados	Métricas	Código aberto
Pan et al. (2026)	Privado, NIST SD4, NIST SD14, SD27, SD302/N2N, FVC2002, FVC2004, FVC2006	Curvas DET, TAR com FAR fixa	Sim

Em (CAPPELLI; FERRARA; MALTONI, 2010) foi proposta uma forma de representação chamada de *Minutia Cylinder-Code*. Ela é baseada em estruturas de dados 3D, os cilindros, que codificam os ângulos das minúcias e as distâncias entre elas.

Nguyen, Cao e Jain (2018) criaram a *MinutiaeNet*, que é um modelo composto por duas redes neurais convolucionais, a *CoarseNet*, para estimar os mapas de *scores* de minúcias com base em informações de domínio, e a *FineNet*, para refinamento dos *scores*.

Engelsma, Cao e Jain (2021) introduziram a *DeepPrint*, uma CNN que extrai uma representação de tamanho fixo utilizando alinhamento por Transformadores Espaciais (JADERBERG et al., 2016), informações de domínio e Aprendizado Multitarefa (CARUANA; PRATT; THRUN, 1997). Os autores não disponibilizaram publicamente uma implementação do modelo. Entretanto, Rohwedder et al. (2023) realizaram a implementação para testes em impressões digitais coletadas de diferentes sensores, e a tornaram pública em um repositório no Github¹.

Ezeobijesi e Bhanu (2017) criaram uma técnica para segmentação de impressões digitais utilizando uma rede neural profunda composta por pilhas de Máquinas de Boltzmann Restritas (*Restricted Boltzmann Machine*, RBM) para delimitar impressões digitais latentes classificando seções das imagens entre duas classes: “impressão digital” e “*background*”.

Tang, Gao e Feng (2017) utilizaram uma Rede Neural Totalmente Convolucional (*Fully Convolutional Network*, FCN) para selecionar seções da imagem com uma probabilidade alta de conter uma minúcia. As seções selecionadas serviram de entrada para uma CNN dedicada à classificação propriamente dita, que também calculava a orientação das minúcias.

Tang et al. (2017) criaram a *FingerNet*, que é uma CNN que extrai um mapa de minúcias utilizando informações de domínio como orientação dos cumes e segmentação, que também são extraídas pela rede, além de realçar as digitais.

¹ <<https://github.com/tim-rohwedder/fixed-length-fingerprint-extractors>>

Zhang, Xin e Feng (2019) utilizaram duas CNNs baseadas na arquitetura ResNet (HE et al., 2016), uma que extrai uma representação de tamanho fixo e outra um mapa de minúcias. A verificação é feita através de cálculo de distâncias de ambas as representações.

Li et al. (2019) desenvolveram uma FCN que extrai uma representação de tamanho fixo com base em atributos globais e locais. O treinamento é feito utilizando porções da imagem (chamadas de “*patches*”) centradas nas minúcias. Na fase de indexação, a rede recebe a imagem completa da digital, e utiliza *Global Average Pooling* (GAP) para agregar todas as informações locais extraídas pela FCN em uma única representação global.

Em (PAN et al., 2026) é apresentado o FLARE, um framework de reconhecimento de impressões digitais baseado na extração de representações de tamanho fixo na forma de um tensor. O método opera em três etapas integradas: inicialmente, alinha a imagem em um sistema de coordenadas padronizado utilizando métodos complementares de estimativa de pose 2D; a seguir, submete a imagem a duas estratégias de aprimoramento (UNetEnh e PriorEnh) que melhoram a clareza das cristas e suprimem o ruído de fundo preservando a textura original da modalidade da captura; por fim, uma rede neural extrai um descritor denso tridimensional que foca exclusivamente na área útil da impressão digital, codificando com alta precisão as informações espaciais globais e locais (minúcias).

Dentre as técnicas que utilizam redes neurais profundas para extração de características, as que se destacaram são o mapa de minúcias, que é uma representação de tamanho variável que armazena a posição de cada minúcia e sua orientação, e as representações de tamanho fixo, que podem ser os *embeddings* das camadas totalmente conectadas das CNNs imediatamente antes do cálculo das probabilidades de cada uma das classes (normalmente de qual dedo a digital foi coletada), isto é, um vetor unidimensional, ou um descritor denso multidimensional, capaz de agregar mais características das digitais, como segmentação e posição das minúcias. Conforme explica Engelsma, Cao e Jain (2021), a vantagem das representações de tamanho fixo é a necessidade de menos poder computacional para verificação, que pode ser feita por um simples cálculo de distância e comparação com um limiar de corte, e de espaço para armazenamento. O DeepPrint e o FLARE são exemplos de técnicas que extraem representações de tamanho fixo.

Outro aspecto que esteve presente nos experimentos foi a utilização de informações de domínio, que são as características intrínsecas das digitais (MALTONI et al., 2022). Quando essas informações são incluídas no treinamento dos modelos ou aprendidas em conjunto com as representações o seu desempenho tende a ser superior ao obtido com atributos mais abstratos, como

apenas a textura das digitais.

Nos experimentos desenvolvidos nos artigos foram utilizados conjuntos de dados públicos e privados, com diferentes características. Por exemplo, Zhang, Xin e Feng (2019) utilizou impressões digitais parciais de alta resolução, o que torna viável a inclusão de informações sobre os atributos de Nível 3 na rede neural. Já em (TANG; GAO; FENG, 2017) foram utilizadas impressões digitais latentes, que são coletadas em cenas de crimes quando pessoas tocam em objetos (MALTONI et al., 2022) e normalmente apresentam uma alta quantidade de ruídos. No caso do FLARE foram necessários diversos bancos de imagens diferentes e técnicas de *Data Augmentation* para treinar cada uma das redes neurais que compõem o *framework*, como o Diverse Pose Fingerprint (DPF), com ampla variação de pose, e imagens de alta resolução com degradações simuladas (variações de umidade, cicatrizes e desfoque).

Destas técnicas, foram encontradas implementações do MCC, *MinutiaeNet*, *FingerNet*, *DeepPrint* e FLARE. Além das implementações das técnicas, foi encontrado o modelo pré-treinado do *DeepPrint*, disponibilizado por Rohwedder et al. (2023) no site ², e também dos módulos que compõem o FLARE, como os pesos das redes de realce UNetEnh e PriorEnh disponíveis no site ³, as redes de alinhamento VotingPose e RegressionPose e a rede de extração da representação densa, FDD, disponíveis no site ⁴, que são repositórios públicos do próprio autor do artigo.

3 Objetivos

Este projeto tem o objetivo de **avaliar diferentes técnicas de extração de características para o reconhecimento de usuários pela impressão digital**. Para isso, será estudado o processo de extração de características a partir de imagens de impressão digital e sua representação.

Os objetivos específicos do projeto são:

- Selecionar conjuntos de dados de impressão digital (ver Seção 4);
- Selecionar técnicas de extração de características para reconhecimento de usuários pela impressão digital;

² <<https://github.com/tim-rohwedder/fixed-length-fingerprint-extractors>>

³ <https://github.com/Yu-Yy/FLARE_ENH>

⁴ <<https://github.com/Yu-Yy/FLARE>>

- Realizar experimentos comparando as diferentes técnicas de extração de características;
- Avaliar as técnicas de extração de características sob diversos aspectos.

4 Metodologia

Nesta seção, será apresentada a metodologia de pesquisa e experimentação. Na Seção 4.1, serão descritos os conjuntos de dados utilizados e nas Seções 4.2, 4.3 e 4.4, serão expostos detalhes sobre as métricas para avaliação, técnicas de extração utilizadas e os experimentos realizados, respectivamente.

4.1 Conjuntos de dados

Foi feita uma pesquisa por conjuntos de dados públicos para a avaliação de modelos para extração de características. A seguir, uma breve descrição sobre os conjuntos de dados encontrados.

4.1.1 *Fingerprint Verification Competition* (FVC)

Foram realizadas algumas competições organizadas por pesquisadores da *University of Bologna* para avaliação de sistemas de reconhecimento de usuários pela impressão digital. As partes A e B dos conjuntos de dados utilizados nas edições de 2000, 2002 e 2004 foram disponibilizadas publicamente como um material adicional da publicação de Maltoni et al. (2022).

Para cada ano da competição, há 4 conjuntos de dados, sendo 3 deles coletados com diferentes sensores e um quarto conjunto de impressões digitais sintéticas geradas através do software SFinGe (MALTONI et al., 2022). Cada um deles foi separado nas partes “A”, com imagens de 100 dedos, e “B”, com imagens de 10 dedos. Para cada dedo há 8 impressões digitais, totalizando 880 imagens em cada conjunto. Portanto, no total, o FVC possui $880 \times 4 \times 3 = 10560$ imagens.

4.1.2 Neurotechnology

A empresa Neurotechnology disponibilizou dois conjuntos de imagens de impressão digital, que podem ser acessados pelo site ⁵. O primeiro conjunto de dados possui imagens de 51 dedos com 8 impressões cada, totalizando 408 imagens capturadas com o leitor *Cross Match Verifier 300*. O segundo possui imagens de 65 dedos com 8 impressões cada, totalizando 520 imagens coletadas com o leitor *DigitalPersona U.are.U 4000*.

⁵ <<https://www.neurotechnology.com/download.html>>

4.2 Métricas

Esta seção descreve algumas métricas usadas na literatura para avaliação dos resultados nos experimentos realizados neste projeto de pesquisa. Essas métricas são: FMR , $FNMR$ e acurácia balanceada (Precise Biometrics, 2014; FERLINI et al., 2021). Os experimentos deste trabalho também apresentam os resultados de EER (*Equal Error Rate*), que representa o ajuste em que $FNMR = FMR$. A métrica EER é bastante usada na literatura de biometria, incluindo em publicações com impressão digital. Exemplos de trabalhos que utilizam a EER como forma de avaliação de técnicas de extração de características de impressões digitais são os de Rohwedder et al. (2023) e Zhang, Xin e Feng (2019).

4.3 Algoritmos

4.3.1 Arquitetura do *DeepPrint*

Engelsma, Cao e Jain (2021) desenvolveram uma Rede Neural Convolucional (*Convolutional Neural Network* ou CNN) que “aprende” a extrair uma representação de tamanho fixo (um vetor) a partir de uma impressão digital. Como entrada a rede recebe uma imagem de tamanho 448×448 em escala de cinza (cada pixel assume um valor de 0 a 255) e passa primeiro pelo módulo de alinhamento. O módulo de alinhamento utiliza uma rede neural de transformação espacial (JADERBERG et al., 2016) para fazer com que a impressão digital na imagem fique no centro.

Em seguida, a imagem passa por uma rede base, que consiste na parte inicial da arquitetura *Inception* v4 (SZEGEDY et al., 2017), isso é, sem os módulos *Inception*. Neste ponto a rede é bifurcada em duas novas redes. A primeira completa a arquitetura da *Inception* v4 incluindo os módulos A, B e C, conforme descrito por Szegedy et al. (2017). O objetivo desta sub-rede é aprender a identificar impressões digitais com base apenas em sua textura (orientação dos cumes, formato da digital, etc), classificados por Maltoni et al. (2022) como atributos de nível 1, de nível global.

A segunda sub-rede possui um módulo A da arquitetura *Inception* v4, e também aprende a identificar impressões digitais com base em atributos globais. Entretanto, ela possui uma tarefa secundária de localizar as minúcias da digital e suas orientações, criando um mapa de minúcias, através de uma segunda CNN que também possui como base o módulo A. Esse compartilhamento de parâmetros entre a rede que classifica com base na textura e a rede que aprende a gerar o

mapa de minúcias, classificado por Maltoni et al. (2022) como um atributo de nível 2, local e mais específico, melhora a capacidade de generalização da rede. Isso é uma técnica conhecida como Aprendizado Multitarefa (CARUANA; PRATT; THRUN, 1997).

Após a imagem de entrada passar por todas as camadas convolucionais, ela passa por camadas totalmente conectadas, e, em seguida, por funções de ativação *softmax*, para calcular a probabilidade de ela pertencer a cada uma das classes, em ambas as sub-redes. Com isso, os 96 pesos das camadas totalmente conectadas são concatenados para formarem um vetor de 192 dimensões. Em seguida os valores reais dos pesos são convertidos para inteiros utilizando normalização por mínimos e máximos. Dessa forma, é utilizada a similaridade de cossenos como medida de distância e um limiar de corte para verificação.

4.3.2 Arquitetura do FLARE

O FLARE (PAN et al., 2026) é um framework de identificação e verificação de impressões digitais baseado em uma rede neural profunda que foi treinada para extrair uma representação na forma de um tensor tridimensional após um pré-processamento que envolve alinhamento, realce e segmentação, também realizados por redes neurais profundas treinadas de forma independente.

Inicialmente a imagem passa por uma etapa de alinhamento que utiliza duas técnicas complementares, uma baseada em regressão (GUAN et al., 2025) e outra baseada em votos (DUAN et al., 2023). A primeira faz uma estimativa da pose da digital com base no seu contorno da imagem enquanto a segunda infere com base em predições locais baseadas em representações densas das cristas. Pan et al. (2026) argumentam que o emprego de técnicas que aliam atributos globais e locais das digitais garante um alinhamento mais preciso.

Após o alinhamento, a imagem é realçada por dois modelos diferentes, o *UNetEnh* e o *PriorEnh*. A *UNetEnh* é uma rede neural convolucional baseada na arquitetura U-Net (RONNEBERGER; FISCHER; BROX, 2015) para segmentação e remoção de ruídos. A rede *PriorEnh*, por sua vez, desempenha o papel crítico de reconstruir parcialmente a estrutura das cristas em áreas severamente danificadas ou apagadas, utilizando para isso um conhecimento prévio sobre a geometria padrão de impressões digitais de boa qualidade.

Para a extração de características, Pan et al. (2026) desenvolveram a Rede de Representação Densa de Tamanho Fixo (*Fixed-length Dense Representation Network*, FDRN). A representação extraída por essa rede, diferente do *DeepPrint*, é uma representação tridimensional que codifica de forma mais natural a segmentação das impressões digitais, assim como as suas minúcias. Ela

é baseada na arquitetura da rede ResNet-34 (HE et al., 2016), com a primeira camada de *Max Pooling* removida para preservação de detalhes mais finos das impressões digitais. De forma semelhante ao que foi proposto em (ENGELSMA; CAO; JAIN, 2021), a rede é dividida em dois ramos para aprendizado multitarefa (CARUANA; PRATT; THRUN, 1997): a primeira sub-rede extrai um mapa de minúcias ao mesmo tempo que aprende a gerar uma representação de tamanho fixo que codifica informações sobre as minúcias; a segunda sub-rede extrai um mapa de segmentação que separa a impressão digital do fundo da imagem enquanto aprende a gerar uma representação de tamanho fixo com base nos padrões dos cumes da digital. Ambas as sub-redes incluem um módulo de incorporação posicional senoidal (VASWANI et al., 2017) para melhorar a capacidade de distinção das representações.

A representação final é obtida ao concatenar os resultados de ambas as sub-redes e calcular o produto de Hadamard com os tensores concatenados e a máscara de segmentação. Sendo f_s e f_m os descritores de textura e minúcia, respectivamente, e S a máscara de segmentação, o descritor final de tamanho fixo é obtido a partir da expressão $f = (f_s \oplus f_m) \odot S$.

Pan et al. (2026) explicam que, em contraste com abordagens que sintetizam a impressão digital em um único vetor global unidimensional (*e.g.*, *DeepPrint*), representações densas multidimensionais retêm a organização estrutural e geométrica das cristas papilares Pan et al. (2026). A agregação global precoce não apenas descarta essas relações espaciais essenciais, mas também deixa o descritor vulnerável a interferências de fundo, comprometendo a correspondência sob forte ruído ou em impressões parciais com variação na área de captura.

Para a verificação entre uma imagem de consulta (*query*, q) e uma de referência (*gallery*, g), os descritores tridimensionais e suas respectivas máscaras de segmentação são vetorizados para o cálculo da similaridade por cosseno normalizado:

$$M_i(q, g) = \frac{f_q'^T \cdot f_g'}{\|f_q \odot S_g\|_F \cdot \|f_g \odot S_q\|_F} \quad (1)$$

Nessa formulação, o numerador realiza o produto escalar $f_q'^T \cdot f_g'$ restrito exclusivamente às regiões válidas de primeiro plano, visto que o fundo já foi anulado pelas respectivas máscaras de segmentação. No denominador, o produto de Hadamard cruzado ($f_q \odot S_g$ e $f_g \odot S_q$) filtra o descritor de uma imagem pela máscara da outra para delimitar a intersecção espacial compartilhada, enquanto a norma de Frobenius ($\|\cdot\|_F$) calcula a magnitude dos tensores nessa região sobreposta, agindo como termo de normalização que previne distorções provocadas por variações no tamanho da área de contato.

4.3.3 Representação baseada em Cilindros

O Minutia Cylinder-Code (MCC) é uma técnica de representação local tridimensional que codifica as relações espaciais e direcionais entre uma minúcia e suas vizinhas dentro de um raio fixo. Como a estrutura cilíndrica é centralizada e alinhada à orientação da minúcia, o método garante invariância a translações e rotações.

O cilindro é discretizado em uma grade tridimensional de células que indicam a probabilidade de presença de minúcias vizinhas. Os valores de cada célula resultam da combinação de contribuições gaussianas espaciais e angulares, normalizadas por uma função sigmoide para atenuar ruídos e distorções, enquanto uma máscara baseada na envoltória convexa descarta regiões fora da área útil.

A comparação entre duas impressões digitais consolida as similaridades entre os cilindros em um escore global, utilizando ordenação simples (LSS) ou atribuição ótima sem duplicidades via algoritmo húngaro (LSA). Para elevar a precisão, variantes com relaxamento iterativo (LSS-R e LSA-R) refinam esses valores ao avaliar a coerência geométrica global entre os pares de minúcias correspondentes.

4.4 Experimentos

Foram realizados experimentos com modelos pré-treinados do DeepPrint e do FLARE. O modelo do DeepPrint foi disponibilizado por Rohwedder et al. (2023), que pode ser obtido através do link⁶. O repositório com o código-fonte utilizado para o treinamento do modelo está disponível publicamente no GitHub⁷.

No caso do FLARE, foram disponibilizados modelos pré-treinados para cada um dos módulos do framework: dois modelos para as redes de alinhamento e estimativa de pose, dois para as redes de realce e um para a rede de extração de representação densa. O código utilizado para o treinamento dos modelos está disponível publicamente no GitHub⁸. A seguir, será descrito como foi feito o treinamento dos modelos e os testes realizados.

Para o MCC, foi utilizada uma implementação disponível publicamente no Github⁹.

⁶ <https://drive.google.com/file/d/1R9v73hFBuy0iihz7v8eDlBcGrMDmQ9TH/view?usp=drive_link>

⁷ <<https://github.com/tim-rohwedder/fixed-length-fingerprint-extractors>>

⁸ <<https://github.com/Yu-Yy/FLARE>>

⁹ <<https://github.com/windhooked/MinutiaCylinderCode>>

4.4.1 Treinamento do DeepPrint

Engelsma, Cao e Jain (2021) utilizaram o conjunto de dados longitudinal (YOON; JAIN, 2015) de cerca de 455000 imagens de 38291 dedos, que não está disponível publicamente. Os autores não disponibilizaram nenhum código-fonte ou modelo pré-treinado. Dessa forma, optamos por utilizar a implementação da arquitetura do DeepPrint e modelo pré-treinado de Rohwedder et al. (2023), que tinha como objetivo avaliar o desempenho preditivo do modelo em imagens coletadas com outros tipos de sensores e com representações de tamanhos diferentes.

Com o intuito de eliminar a necessidade de coletar impressões digitais ou de utilizar um conjunto de dados público os autores utilizaram o SFinGe (MALTONI et al., 2022) para a criação de impressões digitais sintéticas. Para o treinamento, foram utilizadas 10 impressões digitais de 6000 indivíduos, e para validação 4 imagens de 2000 indivíduos, totalizando 68000 imagens. A partir deste banco de imagens, foram geradas novas imagens aplicando-se rotações, reflexões e variações de brilho e contraste de forma aleatória, assim como no artigo original. Uma outra diferença em relação ao experimento de Engelsma, Cao e Jain (2021) foi o tamanho da representação. O modelo pré-treinado gera representações de 512 dimensões, com 256 dimensões em cada sub-rede.

4.4.2 Treinamento do FLARE

Em (PAN et al., 2026) é explicado como cada um dos módulos do *framework* FLARE foi treinado, e quais conjuntos de imagens foram utilizados em cada etapa do treinamento. Nesta seção será descrito brevemente o processo de treinamento das redes neurais que compõem o FLARE.

Os módulos de alinhamento por regressão global direta (GUAN et al., 2025) e votação local densa (DUAN et al., 2023) foram treinados seguindo os métodos originalmente descritos por seus respectivos autores. Foram utilizadas imagens do conjunto de dados do *Diverse Pose Fingerprint* (DPF) e as primeiras 3200 imagens do NIST SD14. Para tornar a rede de alinhamento tolerante a ruídos de fundo foi empregada uma estratégia de aumento de dados que insere de forma aleatória padrões de interferência extraídos do conjunto de imagens MSRA-TD500.

A rede *UNetEnh* também foi treinada utilizando imagens de alta resolução e suas respectivas cópias com desfoque gaussiano, padrões de linhas, caracteres manuscritos do MNIST e sobreposições de fundo do conjunto de dados BID. Já o treinamento da rede *PriorEnh* é estruturado em duas etapas independentes e consecutivas. Primeiro, um *autoencoder* variacional quantizado vetorial (VQ-VAE)(OORD; VINYALS; KAVUKCUOGLU, 2017) é treinado de forma não

supervisionada para reconstruir imagens de alta qualidade do DPF. Através deste processo de aprendizado discreto, a rede cria um dicionário latente (C) composto por 4096 códigos com dimensão de incorporação (d_c) igual a 33. Esse codebook funciona como uma biblioteca geométrica que armazena estruturas de cristas limpas e regulares.

Na segunda etapa de treinamento da PriorEnh, o dicionário de padrões geométricos e o decodificador obtidos na fase anterior são congelados. Em seguida, um codificador seguindo a arquitetura do U-Net, um indexador *GatedPixelCNN* (OORD et al., 2016) e um módulo de transformação de características (CFT) (WANG et al., 2018) são treinados conjuntamente para receber imagens com degradações simuladas e reconstruir suas versões limpas de alta qualidade.

Para o treinamento da FDRN foram utilizados os primeiros 24000 pares de impressões digitais de alta qualidade do NIST SD14 e 2.676 impressões planas de 633 dedos distintos, juntamente com suas respectivas máscaras de segmentação, foram selecionadas do DPF com o intuito de simular impressões digitais incompletas e parciais por meio da aplicação de máscaras binárias.

4.4.3 Extração dos mapas de minúcias com o *FingerNet* para os testes com o MCC

Como o MCC não extrai características das imagens e opera diretamente sobre o mapa de minúcias das impressões digitais, foi necessário utilizar a implementação disponibilizada publicamente no Github¹⁰ pelos próprios autores do artigo sobre o FingerNet (TANG et al., 2017) e pesos pré-calculados em um conjunto de 8000 imagens de impressões digitais latentes para processar os conjuntos de imagens e obter as coordenadas e orientações das imagens.

4.4.4 Testes com os modelos pré-treinados do FLARE e *DeepPrint* e implementação do MCC

Foram realizados testes utilizando todos os conjuntos de dados do FVC e Neurotechnology. Foi calculada uma matriz de pontuação completa entre cada imagem de consulta (*query*) e cada imagem de galeria (*gallery*) (imagem a imagem, sem agregação por sujeito e sem amostragem aleatória). Cada par (*query*, *gallery*) torna-se uma comparação, sendo considerado correspondente quando ambas as amostras pertencem ao mesmo dedo. Para todos os conjuntos de dados foram incluídas na *query* as primeiras 4 imagens de cada dedo, e no conjunto *gallery* as últimas 4 imagens de cada dedo.

Para calcular a *FNMR*, a *FMR* e a *EER*, é necessário definir um limiar de corte que a pontuação deve atingir. Os limiares de corte foram selecionados diretamente das pontuações

¹⁰ <<https://github.com/592692070/FingerNet>>

de cada comparação. Foram considerados 1000 valores igualmente espaçados do intervalo cujos extremos são a pontuação mínima e máxima obtida em cada conjunto de dados, para cada técnica de extração utilizada. Cada um desses valores foi utilizado como limiar de corte para a classificação, e a $FNMR$ e a FMR foram calculadas para cada um deles. A EER obtida foi a média entre a $FNMR$ e a FMR com diferença mínima.

5 Resultados e discussão dos resultados

Esta seção apresenta os resultados obtidos nos experimentos de verificação biométrica com os modelos DeepPrint e FLARE (e suas respectivas variações de alinhamento e realce) sobre as partições de avaliação principal (Parte A) dos sensores reais (DB1 a DB3) das edições FVC2000, FVC2002 e FVC2004, e os resultados do MCC com o FVC2000, bem como sobre os conjuntos de dados CrossMatch e U.are.U disponibilizados pela Neurotechnology. Devido a limitações de recursos computacionais disponíveis, não foi possível aplicar o *FingerNet* em todos os conjuntos de dados. Consequentemente, o MCC não foi testado no FVC2002 e FVC2004.

A Tabela 2 apresenta a comparação de EER obtida pelas abordagens base (sem realce) no ponto de mínima diferença entre FAR e FRR. O método MCC foi avaliado nas bases da edição FVC2000 e da Neurotechnology. Foram também realizados experimentos para avaliar o efeito do realce (PriorEnh e UNetEnh) sobre o desempenho dos modelos. Entretanto, no geral, o realce não aprimorou o desempenho. O resultado dessa avaliação adicional está disponível no repositório no Github¹¹ com o código-fonte dos experimentos.

A Figura 1 apresenta a comparação da distribuição das pontuações de similaridade entre DeepPrint, FLARE (com alinhamento por votação) e MCC para o subconjunto DB1-A da edição FVC2000. Observa-se que, no FLARE, a distribuição das pontuações de impostores (vermelho) permanece concentrada em valores baixos (próximos a 0,2), resultando em uma separação quase total em relação aos usuários genuínos (verde) e justificando as taxas de EER substancialmente menores em comparação ao DeepPrint e ao MCC. No MCC, a sobreposição entre as distribuições no DB1-A é ligeiramente inferior à do DeepPrint, refletindo a menor EER (2,69% contra 3,36%). Os histogramas para os demais conjuntos de dados estão disponíveis no repositório no GitHub e apresentam tendências similares às observadas nos histogramas destacados.

A Figura 2 apresenta a comparação das pontuações entre o DeepPrint, o FLARE (alinhamento por votação) e o MCC para os conjuntos CrossMatch e U.are.U da Neurotechnology.

¹¹ <https://github.com/Thiago-Fernandes-Dias/ic_2025_experimentos>

Tabela 2 – EER (%) dos métodos base (sem realce) nos subconjuntos Parte A do FVC e nas bases da Neurotechnology.

Edição / Origem	Base	DeepPrint	FLARE (Reg.)	FLARE (Vot.)	MCC
FVC2000	DB1-A	3.36	0.81	0.81	2.69
	DB2-A	2.69	0.54	0.19	4.33
	DB3-A	3.85	0.63	0.59	10.21
Média FVC2000		3.30	0.66	0.53	5.74
FVC2002	DB1-A	5.20	0.44	0.25	—
	DB2-A	8.19	0.62	0.69	—
	DB3-A	8.51	3.32	2.08	—
Média FVC2002		7.30	1.46	1.01	—
FVC2004	DB1-A	17.05	0.25	0.24	—
	DB2-A	5.27	1.44	0.87	—
	DB3-A	4.91	0.38	0.31	—
Média FVC2004		9.08	0.69	0.47	—
Média FVC		6.56	0.94	0.67	—
Neurotechnology	CrossMatch	3.31	0.49	0.12	2.10
	U.are.U	2.76	0.58	0.86	1.94
Média Neurotechnology		3.04	0.53	0.49	2.02
Média Geral		5.92	0.86	0.64	—




Figura 1 – Comparação da distribuição das pontuações de similaridade entre DeepPrint, FLARE com alinhamento por votação e MCC para o subconjunto DB1-A do FVC2000.

Nessas bases, capturadas por sensores ópticos de alta qualidade, o MCC apresenta separação superior à do DeepPrint (EER de 2,10% no CrossMatch e 1,94% no U.are.U, frente a 3,31% e 2,76% do DeepPrint), enquanto o FLARE mantém o melhor poder discriminativo geral (EER de 0,12% e 0,86%, respectivamente).

6 Conclusões e perspectivas de trabalhos futuros

Este trabalho apresentou uma avaliação comparativa de técnicas de extração de características de comprimento fixo baseadas em aprendizado profundo para verificação biométrica por impressões digitais, contrastando as arquiteturas *DeepPrint* e *FLARE* nos conjuntos de dados FVC2000,




Figura 2 – Comparação da distribuição das pontuações de similaridade entre DeepPrint, FLARE com alinhamento por votação e MCC para os conjuntos CrossMatch e U.are.U da Neurotechnology.

FVC2002, FVC2004 e nas bases ópticas da Neurotechnology.

Os resultados mostraram um melhor desempenho do FLARE. Entretanto, é importante destacar que as diferenças de desempenho entre DeepPrint e FLARE podem ser decorrentes de suas arquiteturas distintas e dos dados usados pelos modelos pré-treinados usados nos experimentos deste trabalho. Pesquisas futuras podem avaliar o impacto dos dados de treinamento usados para obter os modelos, assim como avaliar outras técnicas.

Destaca-se também a investigação de abordagens conjuntas (*end-to-end*) que treinem simultaneamente as etapas de realce, alinhamento e extração densa, mitigando a propagação de erros entre módulos independentes.

Referências

CAPPELLI, R.; FERRARA, M.; MALTONI, D. Minutia cylinder-code: A new representation and matching technique for fingerprint recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 32, p. 2128–2141, 2010. ISSN 01628828.

CARUANA, R.; PRATT, L.; THRUN, S. *Multitask Learning*. [S.l.], 1997. v. 28, 41-75 p.

DUAN, Y.; FENG, J.; LU, J.; ZHOU, J. Estimating fingerprint pose via dense voting. *Trans. Info. For. Sec.*, IEEE Press, v. 18, p. 2493–2507, jan. 2023. ISSN 1556-6013. Disponível em: <<https://doi.org/10.1109/TIFS.2023.3266625>>.

ENGELSMA, J. J.; CAO, K.; JAIN, A. K. Learning a fixed-length fingerprint representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, IEEE Computer Society, v. 43, p. 1981–1997, 6 2021. ISSN 19393539.

EZEGBIEJESI, J.; BHANU, B. Latent fingerprint image segmentation using deep neural network. In: _____. *Advances in Computer Vision and Pattern Recognition*. [S.l.]: Springer London, 2017. PartF1, p. 83–107.

FERLINI, A.; MA, D.; HARLE, R.; MASCOLO, C. Eargate: gait-based user identification with in-ear microphones. In: . New York, NY, USA: Association for Computing Machinery, 2021. (MobiCom '21), p. 337–349. ISBN 9781450383424.

GUAN, X.; PAN, Z.; FENG, J.; ZHOU, J. Finger pose estimation for under-screen fingerprint sensor. *IEEE Transactions on Information Forensics and Security*, v. 20, p. 12739–12753, 2025.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep Residual Learning for Image Recognition . In: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Los Alamitos, CA, USA: IEEE Computer Society, 2016. p. 770–778. ISSN 1063-6919. Disponível em: <<https://doi.ieeecomputersociety.org/10.1109/CVPR.2016.90>>.

JADERBERG, M.; SIMONYAN, K.; ZISSERMAN, A.; KAVUKCUOGLU, K. Spatial transformer networks. 2 2016. Disponível em: <<http://arxiv.org/abs/1506.02025>>.

JAIN, A.; FLYNN, P.; ROSS, A. *Handbook of Biometrics*. [S.l.]: Springer US, 2007. ISBN 9780387710419.

JAIN, A.; ROSS, A.; PANKANTI, S. Biometrics: a tool for information security. *IEEE Transactions on Information Forensics and Security*, v. 1, n. 2, p. 125–143, 2006.

JAIN, A.; ROSS, A.; PRABHAKAR, S. An introduction to biometric recognition. *IEEE Transactions on Circuits and Systems for Video Technology*, IEEE, v. 14, n. 1, p. 4–20, 2004. ISSN 1051-8215.

LI, R.; SONG, D.; LIU, Y.; FENG, J. Learning global fingerprint features by training a fully convolutional network with local patches. In: *2019 International Conference on Biometrics (ICB)*. [S.l.: s.n.], 2019. p. 1–8.

MALTONI, D.; MAIO, D.; JAIN, A. K.; FENG, J. *Handbook of Fingerprint Recognition*. 3rd. ed. Springer, 2022. ISBN 978-3-030-83624-5. Disponível em: <<https://link.springer.com/book/10.1007/978-3-030-83624-5>>.

MOENSSSENS, A. *Fingerprint Techniques*. Chilton Book Company, 1971. (Inbau law enforcement series). ISBN 9780801955273. Disponível em: <<https://books.google.com.br/books?id=aF6qQgAACAAJ>>.

NGUYEN, D. L.; CAO, K.; JAIN, A. K. Robust minutiae extractor: Integrating deep networks and fingerprint domain knowledge. In: *Proceedings - 2018 International Conference on Biometrics, ICB 2018*. [S.l.]: Institute of Electrical and Electronics Engineers Inc., 2018. p. 9–16. ISBN 9781538642856.

OORD, A. v. d.; KALCHBRENNER, N.; VINYALS, O.; ESPEHOLT, L.; GRAVES, A.; KAVUKCUOGLU, K. Conditional image generation with pixelcnn decoders. In: *Proceedings of the 30th International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2016. (NIPS'16), p. 4797–4805. ISBN 9781510838819.

OORD, A. van den; VINYALS, O.; KAVUKCUOGLU, K. Neural discrete representation learning. In: *Proceedings of the 31st International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2017. (NIPS'17), p. 6309–6318. ISBN 9781510860964.

PAN, Z.; GUAN, X.; DUAN, Y.; FENG, J.; ZHOU, J. Fixed-length dense fingerprint representation with alignment and robust enhancement. *IEEE Transactions on Information Forensics and Security*, IEEE, 2026.

Precise Biometrics. *Understanding Biometric Performance Evaluation*. 2014. Disponível em: <<http://precisebiometrics.com/wp-content/uploads/2014/11/White-Paper-Understanding-Biometric-Performance-Evaluation.pdf>>.

ROHWEDDER, T.; OSORIO-ROIG, D.; RATHGEB, C.; BUSCH, C. Benchmarking fixed-length fingerprint representations across different embedding sizes and sensor types. In: *BIOSIG 2023 - Proceedings of the 22nd International Conference of the Biometrics Special Interest Group*. [S.l.]: Institute of Electrical and Electronics Engineers Inc., 2023. ISBN 9798350336559.

RONNEBERGER, O.; FISCHER, P.; BROX, T. U-net: Convolutional networks for biomedical image segmentation. In: NAVAB, N.; HORNEGGER, J.; WELLS, W. M.; FRANGI, A. F. (Ed.). *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*. Cham: Springer International Publishing, 2015. p. 234–241. ISBN 978-3-319-24574-4.

SZEGEDY, C.; IOFFE, S.; VANHOUCKE, V.; ALEMI, A. Inception-v4, inception-resnet and the impact of residual connections on learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, v. 31, n. 1, Feb. 2017. Disponível em: <<https://ojs.aaai.org/index.php/AAAI/article/view/11231>>.

TANG, Y.; GAO, F.; FENG, J. Latent fingerprint minutia extraction using fully convolutional network. In: *2017 IEEE International Joint Conference on Biometrics (IJCB)*. [S.l.: s.n.], 2017. p. 117–123.

TANG, Y.; GAO, F.; FENG, J.; LIU, Y. Fingernet: An unified deep network for fingerprint minutiae extraction. In: *2017 IEEE International Joint Conference on Biometrics (IJCB)*. [S.l.: s.n.], 2017. p. 108–116.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. In: *Proceedings of the 31st International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2017. (NIPS'17), p. 6000–6010. ISBN 9781510860964.

WANG, X.; YU, K.; DONG, C.; LOY, C. C. Recovering realistic texture in image super-resolution by deep spatial feature transform. In: *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. [S.l.: s.n.], 2018. p. 606–615.

YOON, S.; JAIN, A. K. Longitudinal study of fingerprint recognition. *Proceedings of the National Academy of Sciences*, v. 112, n. 28, p. 8555–8560, 2015. Disponível em: <<https://www.pnas.org/doi/abs/10.1073/pnas.1410272112>>.

ZHANG, F.; XIN, S.; FENG, J. Combining global and minutia deep features for partial high-resolution fingerprint matching. *Pattern Recognition Letters*, v. 119, p. 139–147, 2019. ISSN 0167-8655. Deep Learning for Pattern Recognition. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0167865517303227>>.